

지속 가능한 자동차 제조를 위한 이상 탐지

Anomaly detection for sustainable automotive manufacturing

Smallwood, E., Burke, R. & Barnes, A. P. (2024)

LoDiISA 2024 — Low-Cost Digital Solutions for Industrial Automation, Cambridge, UK

DOI: <https://doi.org/10.1049/icp.2024.3483>

한국어 섹션별 상세 요약본

본 문서는 원 논문의 한국어 요약본입니다. 원 논문은 IET를 통해 발행된 오픈 액세스 논문으로 Creative Commons Attribution License (CC-BY 3.0)에 따라 적절한 출처 표기 시 자유롭게 공유·재구성·번역할 수 있습니다. 본 요약본은 학습 목적이며, 원문 인용 시에는 위 서지정보를 사용해 주세요.

초록 (Abstract) — 핵심 요약

자동차 산업은 사람과 화물의 이동 수단을 제공하지만, 기후변화 대응의 필요성이 커지면서 자동차 제조사는 저탄소 기술(low-carbon technology)을 개발해야 한다는 책임을 지게 되었다. 그러나 이러한 빠른 기술 전환은 특히 차량 부품의 시험(testing) 환경에서 높은 비용, 인력 숙련도 격차(skill gap), 그리고 비효율적이며 에너지 집약적인 관행을 동반한다. 현재 시험 환경에서는 실시간 데이터의 큰 변동성을 잡는 자동 안전 임계값(automated safety threshold)은 있으나, 보다 미묘한 결함(nuanced fault)은 수동 검출에 의존하고 있어 차량 개발을 저해할 수 있다.

이 논문은 학습 데이터가 필요 없는 비지도 데이터 기반 머신러닝(unsupervised, data-driven ML) 이상 탐지 기법이 자동차 시험에서 시험 부품 또는 시험 설비 양쪽의 이상(anomaly)을 식별할 수 있음을 보인다. 저자들은 세 가지 군집화 알고리즘 — k-평균(k-means), 병합 군집화(agglomerative clustering), DBSCAN — 을 (1) 실행 시간(run time)과 (2) 두 이상 사례에 대해 명확한 이상 군집을 만들 수 있는 능력 측면에서 비교한다. 결과는 k-평균이 병합 군집화의 절반 시간에 8개 군집으로 두 이상을 모두 식별했고, DBSCAN은 k-평균보다 다시 절반 빠른 속도였지만 명확한 이상 군집을 만들지 못했다는 점을 보여준다. 이로써 비지도 데이터 기반 이상 탐지가 자동차 제조사의 시험 환경에서 활용 가능한 저비용 디지털 솔루션(low-cost digital solution)임을 시사한다.

1. 서론 (Introduction)

1.1 자동차 산업의 탄소 배출 맥락

2014년 제조업은 전 세계 이산화탄소(CO₂) 배출의 20%를 차지했고, 수송 부문은 또 다른 20%를 기록했다. 수송 부문 배출은 2022년에 23%까지 증가했다. 자동차 산업은 기후변화에 지속적으로 부정적 영향을 끼쳐 왔으며, 정치적·사회적 압박 속에 탈탄소화(decarbonisation) 요구에 응답하면서, 저탄소 기술 탐색과 운영 효율화를 통해 시장 출시까지의 시간(time-to-market)을 단축하려 노력하고 있다.

1.2 자동차 개발의 V-모델과 물리 시험의 자원 집약성

자동차 개발 사이클은 그림 1과 같이 V-모델(V-Model)로 표현된다. 좌측 가지(요구사항·기능·기술 사양 → 컴포넌트·하드웨어/소프트웨어 사양)는 설계·구현(design & implementation) 단계로 이어지고, 우측 가지(컴포넌트 통합·시험 → 전체 차량 통합·시험 → 출시·인수)는 통합·검증 단계를 의미한다. 이 가운데 빨간색으로 강조된 영역이 물리 시험(physical testing)이 일어나는 구간이며, 본 연구에서 다루는 이상 탐지가 적용 가능한 부분이다.

Manufacturers have responded to calls for decarbonisation of the sector, encouraged by political actors and societal shifts,

from testing being used for component design decisions (Figure 1).




그림 1. 자동차 개발 사이클의 V-Model. 빨간색으로 음영 처리된 부분이 차량 시스템 물리 시험 구간이며, 이상 탐지(AD)가 적용 가능한 영역이다.

가상 시뮬레이션만으로는 부품·시스템의 거동을 출시 인증 요건(sign-off requirement)까지 모델링하기 어렵기 때문에 자동차 개발은 물리 시험에 강하게 의존한다. 예컨대 배터리는 노화·열화(aging & degradation) 특성을 파악하기 위해 장시간의 시험 사이클이 필요하다. 시험 대상(unit under test, UUT)이나 시험 설비에서 발생하는 이상은 데이터 수집을 무효화하고 재시험(re-running)을 강요한다. 발견이 늦을수록 그 영향(자원·시간·비용)은 크게 늘어난다.

1.3 기존 이상 탐지의 한계

시험에서 보통 수천 개의 변수가 동시 기록되며, 데이터 품질 진단은 엔지니어 팀의 경험에 크게 의존한다. 새로운 저탄소 기술이 등장할수록 과거 경험만으로 진단하기 어려워진다. 이상을 충분히 잡지 못하면 잘못된 데이터에 근거한 컴포넌트 설계가 승인되고, 그 결정이 V-모델을 따라 상위 컴포넌트와 시스템 설계까지 전파된다. 결과적으로 출시 지연, 성능·안전성 손상, 개발 기간 연장에 따른 비용·에너지 증가가 발생하며, 최악의 경우 리콜로 이어져 재무적·평판적 손실을 초래할 수 있다.

1.4 제조사 관점에서의 두 가지 목표

제조사는 다음 두 가지를 추구한다.

- (1) 시험에서 발생하는 이상을 최소화하고 가능한 빨리 식별하기
- (2) 물리 시험 의존도를 낮추고 가상 시험(virtual testing)으로 전환해 프로토타입 생산 시간·에너지를 절감하기

그러나 가상 모델 자체가 고품질 물리 시험 데이터에 의존하기 때문에, 본 연구는 (1)을 달성해 (2)를 가능하게 한다는 관점에서 첫 번째 목표에 집중한다.

1.5 이상 탐지(Anomaly Detection, AD)의 정의와 제조사 이익

이상 탐지는 데이터에서 비정상적·예상치 못한·이전에 보지 못한 패턴(=이상)을 식별하는 머신러닝 접근법이다. 초기 비용(upfront cost)이 낮고 다음과 같은 이익을 제공한다.

- (1) 1회 정상 시험(first-time-right testing) 보장 및 가상 모델 입력용 고품질 데이터셋 확보로 운영비 절감
- (2) 엔지니어의 데이터 신뢰도 상승, 의사결정 스트레스 감소
- (3) 자율(autonomous) AD가 시험대(test bed) 상시 모니터링 인력을 대체해 숙련도 격차를 완화하고 인력 시간 확보
- (4) 품질이 손상된 채로 시험이 계속될 때 낭비되는 에너지 소비 최소화

이러한 이익은 UN의 17개 지속가능발전목표(SDGs)와도 연결된다. 저탄소 운송 수단(SDG 11)이 더 저렴하게 공급되면(SDG 7) 전 지구적 넷제로 CO₂ 목표(SDG 13)에 기여하고, 개발 시간 단축은 자원 소비 감소(SDG 12)로 이어진다. 또한 조직·에너지 효율 개선 노력과 결합되면 차량 개발 사이클에 내재된 에너지 수요와 CO₂ 임베디드 배출도 줄어든다.

1.6 본 연구의 접근 — 왜 군집화 기반 비지도 학습인가

본 연구는 디젤 승용차 개발 과정에서 수집되는 시계열 시험 데이터에 세 가지 데이터 기반 비지도 군집화(clustering) 기법을 적용한다. 비지도 학습을 선택한 이유는 상용 환경에서 라벨링된 학습 데이터(labelled training data)를 확보하는 것이 자원적으로 비현실적이기 때문이다. 군집화는 특히 오토인코더(autoencoder) 같은 모델 기반 비지도 학습이 요구하는 사전 학습 데이터조차 필요로 하지 않는다는 점에서 더 유리하다. 이는 사전 데이터가 존재하지 않는 신기술·신규 시험 설비를 다룰 때 특히 유익하다. 즉, 본 논문의 접근은 시험 반복 없이도, 심지어 시험이 끝나기 전이라도 이상을 탐지할 잠재력을 제공한다.

이후 본 논문은 2절에서 사용된 데이터셋, 3절에서 군집화 방법론, 4절에서 결과, 5절에서 산업·지속가능성 관점의 논의, 6절에서 결론과 향후 과제를 다룬다.

2. 데이터 (Data Description)

본 연구가 사용한 데이터셋은 Burke et al. (2018; 본 논문 참고문헌 [18])이 생성한 것으로, 새시 동력계(chassis dynamometer)에서 NEDC·WLTC 표준 시험 사이클로 차량 전체를 시험해 얻은 데이터이다. 각 시험은 20~30분 지속되며, 연비·배출 등 차량 성능 지표를 평가하는 데 산업계와 규제 기관이 표준적으로 사용한다.

차량 전수 시험에서는 연료 공급, 후처리(after-treatment), 전기 시스템 등 여러 하위 시스템이 동시에 작동하므로 다수의 센서가 동작 상태를 측정한다. 본 연구의 데이터셋은 약 200개 변수를 포함하며, 이는 (a) 센서 측정값, (b) 절대 습도·배기 성분 질량유량 같은 원시 측정으로부터 계산된 파생값, (c) 차량 ECU(electronic control unit)에서 기록되는 상태 변수, 그리고 (d) 로봇 드라이버 거동 등 시험 설비 성능 관련 항목으로 구성된다.

원본 시험 캠페인은 10일 이내에 걸쳐 여러 차례 주행 사이클 시험을 반복하면서, 시험 간 차량 열적 컨디셔닝(thermal conditioning)을 거쳐 안정적이고 재현 가능한 차량 운전을 시연하는 것이 목적이었다. 데이터 수집 후 약 2주간의 수작업 후처리(manual data processing)를 거쳐 시험 간 의도치 않은 변동이 식별되었다. 원본 연구는 전문가 분석으로 4개의 이상을 식별하고, Partial Least Squares (PLS) 회귀로 자동 식별을 제안했다. 두 방식 모두 이상을 잡는 데 4~8회의 시험 반복이 필요했다.

본 연구는 그중 한 가지 이상을 골라, 단 두 차례의 시험 사이클(=2회 반복)만으로도 군집화 알고리즘이 이상을 검출할 수 있는지 평가했다. 선택한 이상은 차량 제어가 운전 사이클 도중 배기 가열 전략(exhaust heating strategy)을 발동시키는 거동의 변동이었다. 차량의 열적 상태(thermal state)의 작은 차이가 원인으로 추정되며, 배기관에 추가 연료가 분사되는 형태로 나타났다. 흡기 유량 조절(throttling), 연료 분사기 동작, 배기 가스 온도 상승으로 식별 가능하며, 본 연구는 후자 두 특성을 분리해 연료 분사기 활동 + 배기관 3지점의 온도 총 4개 변수로 데이터셋을 구성했다.




Figure 2: Anomalous behaviour of the Post-Fuel Injection variable within one test. Normal behaviour would show this variable to remain at zero.

One anomaly was selected for this study to evaluate performance of clustering algorithms to detect the

그림 2. 한 시험 내 Post-Fuel Injection 변수의 이상 거동. 정상적이라면 이 변수는 0을 유지해야 한다. 그래프는 약 500~600초 구간과 1825~1900초 구간에 2개의 이상 스파이크(anomaly spike)가 발생했음을 보여준다.

군집화 전에는 그림 3과 같이 세 가지 전처리(pre-processing) 변형을 만들었다. 자동차 변수들의 스케일이 서로 달라 군집화 성능에 영향을 줄 것으로 예상했기 때문이다.

- 원시(Raw) — 전처리 없이 그대로 사용
- 표준화(Standardised) — 모든 값을 0~1 범위로 스케일링
- 정규화(Normalised) — 평균 0, 표준편차 1이 되도록 변환

naly, when presented with only two test cycles (Figure 2). anomaly related to the behaviour of the vehicle controller g an exhaust heating strategy. This varying behaviour likely due to small differences in the thermal state of the cle during the duty cycle, but manifested itself through tional fuel injected into the exhaust system. The anomaly be identified through the throttling of intake air flow, fuel stor activity, and increased exhaust gas temperature. The r two characteristics were isolated for this study, resulting four variable dataset including fuel injector activity and e temperature measurements along the exhaust pipe.

Three variants of the dataset were created prior to tering to test the effect of data pre-processing methods ure 3). This was conducted due to the different scales of automotive variable data being expected to impact tering performance. One dataset was left in its raw form, was standardised such that all values were scaled to een 0 and 1, and one was normalised so that the mean standard deviation of the data were 0 and 1 respectively. parison of the algorithms performance across the three processed datasets is presented and discussed in sections d 5 below.




그림 3. 2차 데이터를 군집 분석용으로 준비하는 데이터 처리 방법론. 변수 선별 → 표준화/정규화/원시 분기 → 모델 파라미터 선택 → k-means / 계층 군집화 / DBSCAN 적용.

3. 방법론 (Methodology)

이 절은 세 가지 군집화 알고리즘, 그 하이퍼파라미터 선택 방법, 그리고 성능 평가 방법을 설명한다. 알고리즘은 (a) 학습 데이터 없이 AD를 수행할 수 있는 능력, (b) 비교 문헌에서 보고된 성능, (c) 중심

기반(centroid-based), 병합 기반(agglomerative), 밀도 기반(density-based) 세 가지 군집화 전략을 대표한다는 점을 기준으로 선정되었다.

3.1 알고리즘 설명 (Algorithm descriptions)

k-평균 (k-means)

k-평균은 데이터셋을 k개의 군집으로 나누는 반복적(iterative) 방법이다. 먼저 k개의 초기 군집 중심(cluster centre)을 선택하고, 유클리드 거리(Euclidean distance) 또는 맨해튼 거리(Manhattan distance)로 각 점을 가장 가까운 중심에 할당한다. 군집 중심은 군집에 속한 점들의 평균으로 갱신되며, 할당과 갱신을 점들이 더 이상 이동하지 않을 때까지 반복한다.

병합 군집화 (Agglomerative clustering)

병합 군집화는 계층적(hierarchical) 모델을 사용한다. 처음에는 가장 가까운 두 점부터 시작해 쌍을 병합하다 모든 데이터가 하나의 군집이 될 때까지 계속한다. 점 간 거리는 유클리드 또는 맨해튼 거리를 사용한다. 군집을 어떻게 병합할지 결정하는 기준이 연결 기준(linkage criterion)이다.

- 평균 연결(average linkage): 군집 간 평균 거리
- 완전 연결(complete linkage): 군집 간 최대 거리
- 단일 연결(single linkage): 군집 간 최소 거리

본 연구는 두 거리 척도와 세 연결 기준의 모든 조합(총 18가지 변형)을 평가했다.

DBSCAN (Density-Based Spatial Clustering of Applications with Noise)

DBSCAN은 밀도 기반 군집화 알고리즘 중 가장 널리 사용된다. 임의의 모양을 가진 고밀도 군집(high-density cluster)을 저밀도 영역으로 분리하며, 어디에도 속하지 않는 점을 노이즈(noise)로 분류한다.

3.2 하이퍼파라미터 선택 (Hyperparameter selection)

k-평균과 병합 군집화는 군집 수 k를 미리 정해야 한다. 적절한 k 선택은 군집이 조밀하고 잘 분리되도록 보장하기 위해 중요하다. 본 연구는 두 가지 군집 품질 지표를 함께 사용했다.

- Davies-Bouldin Index (DBI): 군집 내 거리 ÷ 군집 간 거리의 평균 — 값이 낮을수록 좋음
- Calinski-Harabasz Index (CHI): 군집 간 거리 ÷ 군집 내 거리의 평균 — 값이 높을수록 좋음

두 지표가 역관계이므로 0~1로 스케일링한 뒤 함께 플롯하여, 두 곡선이 교차하는 지점을 최적 k로 식별한다. 본 연구에서는 k=2~20 구간을 탐색했다.

DBSCAN은 k 대신 두 가지 파라미터를 정해야 한다. minPts(군집을 이루는 최소 점 수)와 eps(ϵ)(군집의 반경). 변수가 4개인 본 데이터셋에서는 minPts = $4 \times 2 = 8$ 로 설정했다. eps는 각 점과 k-최근접 이웃들 간 평균 거리를 계산해 플롯한 뒤, 그 곡선에서 곡률이 최대가 되는 엘보 포인트(elbow point)를 선택했다.

3.3 평가 (Evaluation)

군집화 결과는 두 가지로 평가했다.

(1) 정성적 평가: 군집화 알고리즘이 두 이상 스파이크에 대해 이상 점만으로 구성된 명확한 군집을 만들 수 있는지를 본다.

- Poor (저성능): 두 이상 스파이크 모두 이상·정상 데이터가 섞인 군집으로 표현됨
- Moderate (중간): 한쪽 이상 스파이크만 이상 데이터만 담은 군집으로 표현됨
- Good (양호): 두 이상 스파이크 모두 이상 데이터만 담은 군집이 적어도 하나씩 존재함

(2) 정량적 평가: 운영성(operationality) 평가를 위해 각 알고리즘의 군집화 소요 시간을 Python의 time 패키지로 측정했다. 하드웨어는 MacBook Pro (2020, 16 GB RAM)로 통일했다.

4. 결과 (Results)

4.1 k-평균 (k-means)

k-평균은 스케일링(scaled)·정규화(normalised) 데이터셋에서 각각 $k=8$, $k=11$ 일 때 이상 데이터에 대해 명확한 군집을 만들었다(그림 4·5). 원시(Raw) 데이터셋에서는 어떤 k 값에서도 명확한 이상 군집이 만들어지지 않아 저성능(Poor)으로 평가되었다. 이는 원시 데이터의 변동성이 k-평균과 호환되지 않을 것이라는 사전 가정과 일치한다.

스케일링 데이터셋· $k=8$ 에서 보라색 군집 1개가 이상 데이터에만 대응했으며, 나머지 군집들은 (정상 위주 + 일부 이상 = true negative 포함), 또는 정상 전용 군집이었다. 정규화 데이터셋· $k=11$ 에서는 갈색 군집 1개가 이상 스파이크에 대응했다.




그림 4. 스케일링 데이터셋에 $k=8$ 을 적용한 k-평균 군집화 결과. 보라색이 이상 전용 군집.




그림 5. 정규화 데이터셋에 $k=11$ 을 적용한 k-평균 군집화 결과. 갈색이 이상 전용 군집.

k -means' runtime on scaled dataset where $k=8$: normalised dataset where $k=11$ ranged between 74-76ms : 92-94ms respectively. Given a 20% faster completion scaled dataset and with fewer clusters, scaled data appeared preferential for the automotive application.

4.2 Agglomerative Clustering

Eighteen permutations were tested for agglomerative clustering, and the performance of each is summarised in Table 1. The algorithm was unable to differentiate between the anomalous data spikes and other data points within the Raw dataset, regardless of linkage criterion or distance measure.

그림 5. 정규화 데이터셋에 $k=11$ 을 적용한 k-평균 군집화 결과. 갈색이 이상 전용 군집.

실행 시간은 스케일링· $k=8$ 에서 74~76 ms, 정규화· $k=11$ 에서 92~94 ms로 측정되어, 스케일링 데이터가 약 20% 더 빠르며 군집 수도 적다. 따라서 자동차 응용에는 스케일링이 더 적합하다.

4.2 병합 군집화 (Agglomerative Clustering)

병합 군집화는 거리 척도(유클리드/맨해튼) × 연결 기준(단일/평균/완전) × 데이터셋(원시/스케일링/정규화)의 총 18가지 조합을 시험했다(표 1).

연결 기준	거리	Raw	Scaled	Normalised
Single (단일)	Euclidean	Poor	Poor	Poor
	Manhattan	Poor	Moderate	Poor

연결 기준	거리	Raw	Scaled	Normalised
Average (평균)	Euclidean	Poor	Good	Poor
	Manhattan	Poor	Good	Poor
Complete (완전)	Euclidean	Poor	Poor	Poor
	Manhattan	Poor	Poor	Poor

표 1. 병합 군집화 18가지 조합의 평가 결과 — 거리 척도와 연결 기준에 따른 군집화 품질.

원시 데이터에서는 어떤 조합도 두 이상 스파이크를 구분하지 못해 모두 Poor였다. 단일 연결·맨해튼 거리·스케일링 데이터셋에서 $k=12$ 일 때 한쪽 이상만 검출되어 Moderate였다. 스케일링 데이터셋 + 평균 연결 + (유클리드 또는 맨해튼) 조합에서 두 이상이 모두 이상 전용 군집으로 분리되어 Good이었다.

병합 군집화는 세 알고리즘 중 가장 느리고 변동이 컸다. 평균 연결·맨해튼은 156~175 ms, 유클리드는 167~174 ms가 걸렸다.

Agglomerative clustering had the longest and most variable runtime of the three algorithms tested, taking between 156-175ms to cluster the scaled dataset with average linkage using the Manhattan distance, and 167-174ms for the Euclidean distance.

When clustered using the Euclidean distance with k set to eight, four distinct clusters across both anomalous datasets were achieved (Figure 6). Only one cluster was created containing only normal data points and the remaining three clusters contained predominantly normal data with some anomalous values. In comparison, k was set to nine when the Manhattan distance was used to cluster the scaled dataset with average linkage (Figure 7). This permutation also resulted in four distinct anomalous clusters to be formed, however three clusters contained only normal points and the remaining two contained normal and anomalous data points.

그림 6. 스케일링 데이터셋에서 평균 연결·유클리드 거리· $k=8$ 병합 군집화 결과. 이상 스파이크에 4개의 명확한 이상 군집(주황·녹색·보라·회색).

From these results, Manhattan distance may have a better ability to distinguish between the anomalous and normal data due to creating a greater number of clusters containing only normal data points compared to when using Euclidean distance. However, given that both distance metrics were able to detect the two anomalous data spikes in the scaled dataset with an average linkage, they appear less influential on the performance on agglomerative clustering of these data. In contrast, the linkage criterion chosen was highly influential as defined clusters were created using an average linkage, but not single or complete linkages.

These results align with those from the k -means algorithm as the average linkage performs in a comparable manner to k -means, and both found eight clusters to successfully separate the anomalous data within the scaled dataset.

그림 7. 스케일링 데이터셋에서 평균 연결·맨해튼 거리· $k=9$ 병합 군집화 결과. 3개의 명확한 이상 군집(녹색·빨강·노랑).

맨해튼 거리가 유클리드보다 정상 데이터 전용 군집을 더 많이 만들어 정상-이상 구분 능력이 더 좋아 보이지만, 두 거리 모두 두 스파이크를 잡는 데 성공한 점을 고려하면 거리 자체의 영향은 본 데이터에서는 작다. 반면 연결 기준은 매우 결정적이었다(평균만 Good, 단일·완전은 부적합).

k -평균 결과와도 정합적이다. 평균 연결 병합과 k -평균 모두 $k=8$ 로 스케일링 데이터의 이상을 성공적으로 분리했다.

4.3 DBSCAN

DBSCAN은 가장 빠른 실행 시간(45~47 ms)을 보였지만, 세 데이터셋 모두에서 저성능(Poor)이었다. 이상 데이터에만 대응하는 군집을 만들지 못했기 때문이다. 단, 거의 모든 이상 점을 하나의 군집으로 묶을 수 있는 유일한 알고리즘이었다.




Figure 8: DBSCAN results with the normalised dataset. clusters were produced using $\text{eps}=0.18$ and $\text{minPts}=8$. (distinct anomalous cluster shown in yellow).

그림 8. 정규화 데이터셋에서 $\text{eps}=0.18$, $\text{minPts}=8$ 로 적용한 DBSCAN 결과. 총 20개 군집이 생성되었고 이상 스파이크는 거의 한 군집(주황색)으로 묶였지만 노란색이 일부 다른 군집에 분산되어 있다.

총 20개 군집 중 3개에 이상 데이터가, 나머지 17개는 정상 전용이었다. 스케일링 데이터셋에서도 유사한 결과였다.

5. 논의 (Discussion)

결과는 비지도 데이터 기반 군집화 알고리즘이 단 2회의 주행 사이클 시험만으로 이상을 효과적으로 검출할 수 있음을 보여준다. 이는 원본 연구가 전문가 분석과 PLS로 6회 시험이 필요했던 것과 비교해 3배 빠른 검출이다. 실무적으로는 4일에 걸친 4회의 저품질 시험과 2주의 후처리·분석을 사전에 방지할 수 있었다는 의미다.

예비 결과는 본 방법론이 전기 파워트레인 내구 시험 같은 다른 자동차 시험 환경에도 적용 가능하다는 점을 시사한다. 또한 [29]의 제트엔진 진동 이상 검출, [30]의 트랙픽 흐름 이상 검출이 k-평균·유클리드 거리로 성공한 사례와도 일치한다. 두 사례 모두 도메인 지식을 활용해 특성을 추출한 축소 데이터에 적용한 점이 공통적이다. 특히 [30]은 합성·실제 데이터 양쪽에서 k-평균의 확장성(scalability)을 보였다.

알고리즘 비교 — 운영성과 성능

두 평가 기준(군집화 성능 + 실행 시간)을 종합하면, 본 자동차 시험 데이터셋에서는 k-평균이 가장 적합하다. 병합 군집화와 군집화 품질은 비슷하지만, k-평균이 정상-이상 구분(정상 전용 군집이 더 많이 생성됨)에서 우세하다. [11]과 [21]의 사례에서도 조향각 센서 이상 검출, 제품 가격 이상 검출 등 다른 도메인에서 계층 군집화와 k-평균이 다른 알고리즘들을 능가했다. [21]에서 DBSCAN은 8개 알고리즘 비교에서 Borda count 기준 끝에서 3번째였는데, 단일 점 군집을 다수 생성하는 거동 때문이며, 본 연구의 20개 군집 결과와도 일치한다.

거짓 양성(false positive) vs 참 음성(true negative)의 트레이드오프

군집을 어떻게 라벨링·해석하느냐에 따라 혼합 군집(정상+이상이 섞인 군집)은 거짓 양성(=정상인데 이상으로 인식)이나 참 음성(=이상인데 정상으로 인식)으로 해석될 수 있다. 자동차 개발에서는 결함을 놓치는 것이 더 큰 손실이므로 거짓 양성이 참 음성보다 일반적으로 더 선호된다. 다만 거짓 양성이 너무 많으면 엔지니어 업무를 방해하므로, AD 도입 시 그 균형을 신중히 설정해야 한다.

실행 시간 비교

k-평균은 비슷한 군집 수로 병합 군집화보다 최대 2.2배 빨랐다. DBSCAN은 병합보다 최대 3.8배, k-평균보다 최대 2.0배 빨랐지만, 명확한 이상 군집을 만들지 못한 데다 하이퍼파라미터 최적화에 더 많은 전문가 개입을 요구해 상용 제조 환경에는 부적합하다. 흥미롭게도 이는 [31]이 보고한 'DBSCAN은 계산 자원이 많이 든다'는

결론과는 반대 양상이다.

실행 시간 vs 성능 — 응용 맥락별 선택

선택 기준은 응용 맥락에 달려 있다. 1시간 미만의 짧은 컴포넌트 시험은 작은 데이터셋의 이상을 잘 잡는 군집화 성능이 우선이며, 12개월 이상 장기 시험은 비록 거짓 양성이 다소 증가해도 결과를 빠르게 주는 알고리즘이 유리할 수 있다. AD를 시험 중에 실시간 가깝게 돌릴지, 시험 종료 후 일괄 검사할지에 따라 선택이 달라진다. 본 연구는 후자의 사례에 해당한다. 핵심은 본 연구의 비지도·데이터 기반 ML 접근이 원본 연구의 4~8회 반복 대비 단 2회의 시험으로도 이상을 잡아냈다는 점이다.

5.1 한계 및 향후 과제 (Limitations and Future Work)

한계는 주로 하이퍼파라미터 선택과 성능 평가의 주관성에 있다. DBI·CHI를 사용해 주관성을 줄이고 재현성을 높였지만, k -평균과 병합 군집화의 k 선택은 결국 DBI·CHI 교차 지점에 대한 정성적 해석에 의존한다. 본 연구의 병합 18조합 중 다수가 Poor였던 점이 이를 보여준다. 평가 자체도 본 연구에서는 이상 존재를 알고 있어 Poor/Moderate/Good을 정의할 수 있었지만, 실 운영에서는 엔지니어가 사전 정보 없이 군집을 평가해야 한다. 향후 과제로는 이상 군집을 정량적으로 식별하는 분석 기법을 개발해 재현성·산업 적용성을 극대화할 필요가 있다.

6. 결론 (Conclusion)

본 연구는 비지도 군집화 알고리즘이 학습 데이터 없이도 자동차 개발 사이클의 시계열 데이터에서 이상을 검출할 수 있음을 보였다. 단 2회의 주행 사이클만으로 이상을 검출함으로써, 원본 연구의 6회 반복 대비 운영 효율을 66% 이상 개선할 수 있다. 저품질 주행 사이클 시험과 수작업 후처리에 드는 시간·에너지·인력 자원의 절감이 핵심 이익이다.

k -평균이 가장 우수했다. 두 이상 스파이크를 적은 수의 명확한 군집으로 검출했고, 병합 군집화 대비 2.2배 빨랐다. DBSCAN은 k -평균보다 2배 빠르지만 하이퍼파라미터 민감도가 높고 명확한 이상 군집을 만들지 못해 상용 AD에는 덜 적합하다고 결론 내렸다.

AD가 자동차 시계열 시험 데이터에 적용 가능성이 입증됨에 따라, 이 기술은 다음 방식으로 자동차 산업에 기여할 수 있다.

- (1) 학습 데이터 불필요 → 모델 학습 비용·계산 자원 부담 절감, 중소 제조사 접근성 향상
- (2) 잘못된 데이터에 기반한 설계 결정의 지연 비용 감소
- (3) 필요한 시험 횟수 감소
- (4) 인력의 낭비 노력 감소

이러한 효과는 자동차 제조 부문의 지속가능성을 끌어올리고, 글로벌 기후변화 완화 노력에 기여한다.

부록. EMS 프로젝트와의 연결 (학습 노트)

현재 진행 중이신 Honda R&D EMS 데이터 분석 프로젝트(Phase 4 — 이상 탐지)와의 연결점을 정리하면 다음과 같다.

공통점

- 현실 시스템에서 발생하는 시계열 이상 탐지라는 본질적으로 동일한 문제 영역
- 산업 환경 특성상 라벨링된 학습 데이터의 부재 — 비지도 학습 필요성 동일
- 이상 검출이 늦으면 운영 비용·에너지 낭비가 누적된다는 동일한 비즈니스 임팩트 구조

EMS 프로젝트에 적용 시 고려 사항

- 본 논문의 데이터셋(자동차 시험, 4변수·약 1800~1900초)은 EMS의 다변량 6년치 데이터에 비해 매우 작다. k -평균을 직접 적용하기 전, 도메인 지식 기반의 특성 선택(feature selection)이 선행되어야 군집화가

의미를 갖는다.

- EMS의 경우 PV·CHP·HVAC 같은 운영 모드(regime)가 시간대·계절에 따라 바뀐다. 모드별로 군집화 모델을 따로 두거나, 모드를 추가 변수로 넣는 설계가 필요하다.
- 본 논문의 결론과 같이 k-평균을 1차 후보로 사용하되, 운영 시 거짓 양성 비율을 모니터링하며 임계값을 조정하는 방식이 안정적이다.
- DBSCAN은 본 논문에서는 부적합 결론이었지만, EMS의 게이트웨이 장애 같은 긴 공백(gap)·드문 패턴은 밀도 기반 접근이 유리할 수 있다. eps·minPts를 도메인 지식으로 설정한 뒤 비교 평가하는 것이 좋다.
- 평가 지표로 본 논문이 사용한 DBI·CHI 외에 EMS에서는 도메인 검증을 위해 이벤트 라벨(예: regime change 시점)과의 정합성을 함께 보는 혼합 평가가 필요하다.

부트캠프 학습 관점에서 핵심 takeaway

- 비지도 학습이 산업에서 통하는 이유: 라벨 부재 + 신기술이라 사전 데이터 없음 → 군집화가 진입 장벽 가장 낮음
- 전처리가 결과를 좌우한다: Raw 데이터에서는 어떤 알고리즘도 실패. 스케일링/정규화의 효과가 결정적
- 알고리즘 선택은 단일 지표가 아닌 트레이드오프: 정확도 ↔ 실행 시간 ↔ 하이퍼파라미터 민감도
- 운영성(operationality)이라는 개념: 학술적 성능이 아니라 실무 엔지니어가 운용 가능한가가 최종 기준

출처 (Citation)

Smallwood, E., Burke, R., & Barnes, A. P. (2024). Anomaly detection for sustainable automotive manufacturing. Low-Cost Digital Solutions for Industrial Automation (LoDiISA 2024), Cambridge, UK, 1-2 October 2024. <https://doi.org/10.1049/icp.2024.3483>

본 요약본은 학습용 비공식 한국어 정리이며, 원문은 IET의 오픈 액세스 정책에 따라 Creative Commons Attribution License (CC-BY 3.0; <http://creativecommons.org/licenses/by/3.0/>)로 공개되어 있습니다. 인용·재배포 시 위 서지정보를 반드시 표기해 주세요.